

GRPO với ràng buộc tỷ lệ đúng → sai

BẢO CÁO THỬ NGHIỆM NGẮN | Seed 42 | Hoàn tất 05/10/2026

1. Bài toán và mục tiêu

Khi hậu huấn luyện trên nhiều chủ đề toán, model có thể giải được thêm bài vốn sai nhưng đồng thời làm sai bài vốn đúng. Thử nghiệm này kiểm tra liệu một **ràng buộc mềm** có giúp giảm hiện tượng **đúng → sai**, trong khi vẫn cho model học thêm hay không.

2. Thiết lập thử nghiệm

Thành phần	Thiết lập
Model và cách train	Qwen2.5-1.5B-Instruct; QLoRA 4-bit, rank 8. Giữ trọng số gốc, cập nhật adapter. Không có giai đoạn SFT riêng trước RL.
Dữ liệu	Subset MATH có đáp án nguyên: đại số, hình học, lý thuyết số, tổ hợp và xác suất.
Các tập dữ liệu	128 bài train; 512 anchor ứng viên, chọn được 153 bài model gốc giải đúng; 160 validation; 640 test. Các tập tách biệt.
Ngân sách mỗi nhánh	128 bước, 4 lời giải/bước, 2 policy epochs; tối đa 1024 token/lượt sinh. Một seed: 42.

3. Phương pháp và luồng chạy

GRPO: model tự sinh 4 lời giải cho một bài train. Đáp án cuối đúng nhận reward 1, sai nhận 0. Reward được chuẩn hóa trong nhóm thành advantage; loss dùng tỷ lệ xác suất có clipping để tăng xác suất lời giải tốt và giảm xác suất lời giải kém. Nhóm có reward đồng nhất không tạo cập nhật GRPO.

Nhánh ràng buộc: mỗi bước kiểm tra thêm một bài anchor. Với từng chủ đề k , sau cửa sổ 32 bước, đo tỷ lệ anchor từng đúng nhưng hiện trả lời sai, rồi điều chỉnh hệ số λ riêng cho chủ đề đó:

$$\lambda_k \leftarrow \text{clip}[\lambda_k + 0,30 \times (\text{flip-rate}_k - 0,10), 0, 1]$$

$$L_{\text{tổng}} = L_{\text{GRPO}} + \lambda_k \times L_{\text{anchor}}$$

Loss anchor là trung bình âm log-xác suất các token **lời giải chuẩn từ dataset**, tính bằng model với adapter hiện tại; không tính token đề. λ tăng thì sức tác động của gradient anchor tăng. λ bắt đầu bằng 0 và giá trị mới dùng từ cửa sổ tiếp theo. Đây là surrogate giữ khả năng, không phải bảo đảm cứng mọi đáp án đều được giữ đúng.

Luồng: đóng băng dữ liệu → chọn/audit anchor ban đầu → train độc lập hai nhánh → đánh giá cùng validation/test → so sánh theo từng câu → vẽ biểu đồ.

Kết quả và nhận xét

Cùng 640 bài test; 194 bài được model ban đầu giải đúng.

Chỉ số	Ban đầu	GRPO	GRPO + ràng buộc
Số bài đúng / 640	194	199	200
Accuracy	30,31%	31,09%	31,25%
Đúng → sai / 194 bài ban đầu đúng	-	20	17
Tỷ lệ đúng → sai	-	10,31%	8,76%
Sai → đúng	-	25	23
Thời gian train, gồm audit	-	3,32 giờ	3,89 giờ

4. Kết quả nói lên điều gì?

So với GRPO, nhánh ràng buộc **giữ được thêm 3 bài đúng**, nhưng **sửa ít hơn 2 bài sai**. Vì vậy số bài đúng cuối cùng chỉ tăng thêm 1 bài, tương đương **+0,156 điểm phần trăm accuracy**. Đây là đánh đổi giữa giữ khả năng và học cải thiện, chưa phải một mức tăng hiệu năng lớn.

Theo chủ đề, số bài đúng → sai giảm ở **đại số: 9 → 7** và **hình học: 2 → 1**; không đổi ở lý thuyết số: 4 → 4 và tổ hợp/xác suất: 5 → 5. Trên cùng 615 câu không bị cắt ở cả ba model, số flip vẫn giảm 19 → 16; phân tích này chỉ bổ sung, không thay thế toàn bộ test.

Chi phí train tăng khoảng **34 phút (17,2%)**. Hai nhánh có cùng ngân sách sinh lời giải RL nhưng số optimizer update khác nhau: 98 so với 150, vì loss anchor có thể cập nhật khi nhóm RL không có advantage. Toàn pipeline ghi nhận **15,85 giờ**, có dùng lại cache suy luận ban đầu; thời gian tạo cache ở lượt trước không nằm trong con số này.

5. Hạn chế và mức độ tin cậy

Chỉ chạy một seed và một subset MATH có đáp án nguyên. Test đã được xem trước khi quyết định chạy lại cơ chế feedback cửa sổ, nên đây là **thử nghiệm thăm dò hậu nghiệm**, không phải đánh giá xác nhận độc lập. Giới hạn 1024 token vẫn tồn tại; tỷ lệ bị cắt trên test là 3,13% với GRPO và 3,44% với ràng buộc.

Bootstrap theo cặp, phân tầng theo chủ đề (2.000 lần): chênh lệch accuracy có khoảng tin cậy 95% **[-0,781; +1,094]** điểm phần trăm; chênh lệch flip-rate có khoảng **[-3,941; +0,532]** điểm phần trăm. Cả hai còn chứa 0: **chưa đủ bằng chứng khẳng định cải thiện ổn định**.

6. Kết luận và hướng phát triển

Trong lượt run này, ràng buộc giảm số bài đúng → sai từ 20 xuống 17, giữ accuracy gần tương đương GRPO và làm tăng chi phí train. Kết quả là tín hiệu nhỏ về khả năng giữ đáp án đúng. Muốn kiểm chứng tiếp cần test độc lập và nhiều seed; đồng thời kiểm tra độ nhạy của ngưỡng flip-rate, tốc độ cập nhật λ và chất lượng anchor, rồi so sánh trên cùng chi phí tính toán.

Nguồn số liệu trong repo: results/comparison.csv, results/paired_statistics.csv, results/run_timing.json; cấu hình: configs/math_retention.json. Biểu đồ và lịch λ : visualize_results.ipynb. Báo cáo chỉ dùng lượt run được giữ hiện tại.