

GRPO với ràng buộc mềm để giảm tỷ lệ đúng → sai

Post-training Language Models via Constrained Optimization
Run seed 42 hoàn tất 05/10/2026 | Báo cáo cập nhật 06/10/2026

Tóm tắt

Thử nghiệm so sánh GRPO và GRPO có ràng buộc mềm theo chủ đề trên Qwen2.5-1.5B-Instruct. Trên 640 câu test, số bài đúng → sai giảm từ **20 xuống 17**, nhưng số bài sai → đúng cũng giảm từ **25 xuống 23**. Nhánh ràng buộc đúng 200 câu, GRPO đúng 199 câu; train tốn thêm khoảng 34 phút. Đây là **tín hiệu nhỏ, chưa đủ khẳng định cải thiện ổn định**.

1. Vấn đề cần giải quyết

Hậu huấn luyện có thể giúp model giải được bài vốn sai, đồng thời làm sai bài vốn đúng. Nếu chỉ xem accuracy, ta có thể bỏ qua sự thay đổi này. Ví dụ, sửa 10 bài sai nhưng làm sai 10 bài đúng thì accuracy không đổi. Mục tiêu ở đây là hạn chế hồi quy đáp án và vẫn cho model học thêm.

Các bài dùng chung tham số nên có thể tác động lẫn nhau khi cập nhật. Đây là khả năng giải thích, chưa phải nguyên nhân được chứng minh bằng gradient trong run này. Đúng → sai là hồi quy đầu ra; không tự động chứng minh model mất hoàn toàn kỹ năng.

2. Model và dữ liệu

Model: Qwen/Qwen2.5-1.5B-Instruct, không phải bản Math. QLoRA giữ trọng số gốc, cập nhật adapter rank 8. Model đã pretrained/instruction-tuned; run không train từ đầu và không có SFT riêng trước RL.

Tập	Số bài	Vai trò
Train	128 (32/chủ đề)	Sinh lời giải và tính loss GRPO
Anchor ứng viên	512 (128/chủ đề)	Chọn được 153 bài model ban đầu giải đúng
Validation	160 (40/chủ đề)	Đánh giá bổ sung, không làm anchor
Test	640 (160/chủ đề)	So sánh kết quả cuối trên cùng câu hỏi

Nguồn MATH: đại số, hình học, lý thuyết số, tổ hợp và xác suất. Chỉ lấy đáp án nguyên và bài đáp ứng giới hạn độ dài; các tập tách biệt và đã đóng băng. Đây không phải benchmark MATH đầy đủ. 153 anchor và 194 bài test ban đầu đúng là hai tập khác nhau.

Cấu hình: 128 bước/nhánh, 4 lời giải/bước, 2 policy epochs; AdamW, learning rate $5e-6$, ratio clip 0,2. Giới hạn prompt 512 token; sinh train/eval/anchor 1024 token; đề + gold solution tối đa 1536 token. QLoRA NF4 4-bit, double quantization; rank 8, alpha 16, dropout 0, q_proj/v_proj. Train sampling temperature 0,8 và top_p 0,95; đánh giá greedy.

3. GRPO học như thế nào?

Từ lời giải tự sinh → reward → advantage → loss → cập nhật adapter

3.1. Tạo tín hiệu học

Mỗi bước lấy một bài train và sinh 4 lời giải. Chấm đáp án nguyên trong boxed answer cuối: đúng nhận reward 1; sai hoặc không đọc được định dạng nhận 0. Bốn chủ đề được lấy luân phiên, không học xong chủ đề này rồi mới sang chủ đề khác.

Ví dụ minh họa: chọn 3 người từ 6 người có 20 cách. Nếu model sinh bốn đáp án [20, 15, 20, 10], reward là [1, 0, 1, 0]. Advantage chuẩn hóa reward theo trung bình của nhóm:

$$A_i = (R_i - \text{trung bình reward}) / (\text{độ lệch chuẩn} + 10^{-8})$$

Đáp án	Reward	Advantage	Hướng khuyến khích
20	1	+1	Tăng xác suất lời giải
15	0	-1	Giảm xác suất lời giải
20	1	+1	Tăng xác suất lời giải
10	0	-1	Giảm xác suất lời giải

Nhóm có cả đúng và sai được gọi là mixed group. Nếu cả 4 đều đúng hoặc đều sai, advantage không tạo tín hiệu phân biệt; code bỏ cập nhật GRPO của nhóm đó.

3.2. Loss GRPO trong code

Với token j của lời giải i, tính tỷ lệ xác suất hiện tại so với xác suất lưu trước các policy epoch của group:

$$\rho_{i,j} = p_{\theta}(y_{i,j} | x, y_{i,<j}) / p_{\text{old}}(y_{i,j} | x, y_{i,<j})$$

$$L_{\text{GRPO}} = -(1/G) \sum_i (1/T_i) \sum_j \min[\rho_{i,j} A_i, \text{clip}(\rho_{i,j}, 0.8, 1.2) A_i]$$

G = 4 lời giải; T_i là độ dài lời giải i. Lấy trung bình trên token rồi trên group; dấu âm chuyển mục tiêu tối đa hóa thành loss tối thiểu hóa. Clipping hạn chế động lực thay đổi xác suất quá mạnh, không phải bảo đảm cứng xác suất chỉ thay đổi trong đoạn đó.

p_old là model trước update của group hiện tại, không luôn là base model trước cả run. Mỗi group có 2 policy epochs. Hai nhánh hiện tại không có reference-KL trong loss; đây là comparator GRPO cục bộ, không claim tái lập toàn bộ setup paper GRPO gốc.

4. Loss anchor và vai trò của λ

Cùng model gốc, nhưng adapter hiện tại đã thay đổi sau các bước train

4.1. Anchor là bài nào?

Trong 512 bài ứng viên, chọn 153 bài model ban đầu giải đúng: 64 đại số, 22 hình học, 38 lý thuyết số, 29 tổ hợp/xác suất. Mỗi bước kiểm tra một anchor với model hiện tại. Không kiểm tra cả tập mỗi bước; bài có thể được chọn lại khi vòng chọn quay về đầu danh sách.

Ví dụ minh họa: model ban đầu giải đúng $2x + 3 = 11$ với $x = 4$. Nếu đang train mà trả lời $x = 5$, ghi nhận một lượt hồi quy. Lời giải chuẩn vẫn là: trừ 3 để được $2x = 8$, chia 2 để được $x = 4$.

4.2. Loss được tính trên model nào?

Model ban đầu và model hiện tại dùng cùng trọng số gốc. Khác nhau là adapter LoRA đã được cập nhật:

$$W_{\text{hiện dụng}} = W_{\text{gốc}} + \Delta W_{\text{LoRA}}$$

Code đưa đề và **lời giải chuẩn từ dataset** vào model hiện tại. Tại mỗi vị trí, đo xác suất token chuẩn tiếp theo khi đã có các token chuẩn trước đó:

$$L_{\text{anchor}} = -(1/T) \sum_j \log p_{\theta}(y_j^* | x, y_{<j}^*)$$

Tính trên toàn bộ token lời giải chuẩn và EOS của **một bài anchor đang chọn**, không tính token đề; không tính toàn bộ tập mỗi bước. Nhấn không phải lời giải cũ base model từng sinh. Đây là thành phần học có giám sát phụ trợ trong quá trình RL.

Ví dụ một token: xác suất chuẩn 0,8 cho $-\ln(0,8) \approx 0,223$; xác suất 0,2 cho loss $\approx 1,609$. Giảm loss khuyến khích sinh lời giải chuẩn dễ hơn, nhưng không bảo đảm greedy decoding sẽ giải đúng.

4.3. λ thay đổi sức tác động của anchor

$$\begin{aligned} L_{\text{tổng}} &= L_{\text{GRPO}} + \lambda_k L_{\text{anchor}} \\ \text{grad}(L_{\text{tổng}}) &= \text{grad}(L_{\text{GRPO}}) + \lambda_k \text{grad}(L_{\text{anchor}}) \end{aligned}$$

λ là hệ số riêng cho chủ đề k . $\lambda = 0$: chỉ kiểm tra anchor, chưa thêm loss. λ tăng: gradient giữ lời giải chuẩn tác động mạnh hơn; λ giảm: tác động yếu đi. Hai gradient được cộng trước cùng optimizer update, không phải hai bước train luân phiên.

$\lambda = 0,1$ không có nghĩa 10% học anchor và 90% học GRPO, vì độ lớn gradient khác nhau. Chỉ adapter được cập nhật; trọng số gốc giữ nguyên.

5. Feedback và workflow thực tế

Ngưỡng 10% là mục tiêu trên mẫu anchor quan sát, không phải bảo đảm test

5.1. Điều chỉnh λ sau mỗi 32 bước

λ khởi tạo 0. Trong cửa sổ 32 bước toàn cục, mỗi chủ đề có 8 lượt kiểm tra. Sau cửa sổ, tính tỷ lệ anchor trả lời sai rồi điều chỉnh λ :

$$f_k = \text{số lượt anchor sai} / \text{tổng lượt kiểm tra chủ đề } k$$
$$\lambda_k \leftarrow \text{clip}[\lambda_k + 0,30(f_k - 0,10), 0, 1]$$

0,10 là ngưỡng mục tiêu; 0,30 là tốc độ điều chỉnh λ , khác learning rate model. Vượt ngưỡng thì tăng λ , dưới ngưỡng thì giảm, giữ λ trong $[0; 1]$. Ví dụ 1 lượt sai/8 = 12,5%, λ đang 0 thì giá trị mới là **0,0075**.

Giá trị mới dùng từ cửa sổ tiếp theo. 32 bước đầu chưa có anchor loss nhưng vẫn theo dõi. λ sau bước 128 chỉ được ghi log vì run kết thúc. Nếu $\lambda > 0$ và group RL không có advantage, anchor loss vẫn có thể tạo update.

5.2. Vì sao là ràng buộc mềm?

Tỷ lệ đúng $\rightarrow$ sai từ đáp án rồi rác không được lấy gradient trực tiếp. Nó điều khiển λ ; gold loss là đại lượng thay thế có thể lấy gradient. Cơ chế này không phải projection, CPO hoặc lời giải chính xác của tối ưu có ràng buộc flip-rate. Không bảo đảm tất cả bài từng đúng đều đúng hay test flip-rate dưới 10%.

5.3. Quy trình và điều kiện so sánh

Bước	Việc thực hiện
1. Đóng băng dữ liệu	Giữ train, anchor, validation, test riêng biệt.
2. Chọn/audit anchor	Chọn 153 bài đúng ban đầu; audit cả hai model có adapter mới trước update. Không có mismatch.
3. Train độc lập	Cùng base, seed, thứ tự bài, group/token limit. GRPO chỉ policy loss; nhánh kia thêm $\lambda \times$ gold loss khi $\lambda > 0$.
4. Đánh giá cuối	Chạy đủ 128 bước, dùng adapter cuối và cùng bộ câu hỏi; không chọn checkpoint theo test.
5. Phân tích	Accuracy, flip, gain, từng chủ đề, compute, bootstrap và biểu đồ.

Loader train/evaluation thống nhất chuẩn bị QLoRA để tránh lệch precision. Seed đặt lại sau audit. Cùng ngân sách sampling không đồng nghĩa cùng rollout, số optimizer update hay tổng compute.

6. Kết quả và đánh đổi

194 bài test ban đầu đúng: mẫu số để tính tỷ lệ đúng → sai

Chỉ số	Ban đầu	GRPO	Ràng buộc
Đúng / 640 test	194	199	200
Accuracy	30,31%	31,09%	31,25%
Đúng → sai / 194	-	20 (10,31%)	17 (8,76%)
Sai → đúng	-	25	23
Validation accuracy	28,13%	27,50%	28,13%
Worst topic accuracy	21,25%	23,75%	24,38%
Test bị cắt	2,50%	3,13%	3,44%
Train gồm audit	-	3,32 giờ	3,89 giờ

6.1. Đọc số bài thay đổi

GRPO: $194 - 20 + 25 = 199$. Ràng buộc: $194 - 17 + 23 = 200$. Nhánh ràng buộc ít hơn 3 bài đúng → sai nhưng cũng ít hơn 2 bài sai → đúng: ròng hơn **1 bài, +0,156 điểm phần trăm accuracy**. Flip-rate giảm 1,546 điểm phần trăm. Đây là chênh lệch số lượng; hai nhánh có thể đúng trên những câu khác nhau.


6.2. Chi phí không chỉ là token RL

Chỉ số train	GRPO	Ràng buộc
Group RL / lời giải RL	128 / 512	128 / 512
Mixed groups	49 (38,28%)	43 (33,59%)
Token sinh lời giải RL	149.416	148.054
Token kiểm tra anchor	0	36.269
Token audit trước train	38.403	38.403
Optimizer updates	98	150
Policy epoch có anchor loss	0	96

Train tăng **34,27 phút (17,2%)**. Tổng pipeline **15,85 giờ** đã dùng lại cache suy luận ban đầu; không gồm chi phí tạo cache ở run trước. Token gold solution còn cần forward/backward, nên gần bằng token RL không có nghĩa gần bằng compute.

7. Đọc biểu đồ tổng thể

Các hình lấy trực tiếp từ notebook của lượt run được giữ



Hình 1. Accuracy, tỷ lệ đúng → sai, thời gian train gồm audit và số bài thay đổi so với model ban đầu.

7.1. Ý nghĩa của bốn ô

Trên trái: ràng buộc 31,25%, GRPO 31,09%. Accuracy cao hơn chỉ tương ứng một câu. Trục không bắt đầu từ 0, vì vậy cần đọc nhãn số thay vì chỉ nhìn chiều cao cột.

Trên phải: flip-rate giảm 10,31% → 8,76%. Mẫu số là 194 câu ban đầu đúng, không phải 640 câu test. Cột base bằng 0 vì so model với chính nó.

Dưới trái: nhánh ràng buộc train lâu hơn; thời gian gồm audit nhưng không gồm toàn bộ evaluation. Cột base bằng 0 không có nghĩa suy luận base miễn phí.

Dưới phải: phải xem cả đúng → sai và sai → đúng. Ràng buộc hồi quy ít hơn nhưng cũng sửa ít hơn; chính sự đánh đổi này làm accuracy cuối gần tương đương.


7.2. Metric nào có thể gây nhầm?

Capped: chạm trần token mà chưa sinh EOS, không mặc định đáp án sai. **No box:** không có boxed answer hoàn chỉnh, không tự động chứng minh toàn suy luận sai. **Mixed group:** có cả reward 0/1, tạo tín hiệu GRPO. **Macro accuracy:** mean bốn chủ đề, bằng accuracy toàn bộ ở run cân bằng này.

Bài bị cắt vẫn nằm trong metric chính. Trên cùng 615 câu không bị cắt ở cả ba model, GRPO có 19 flip và ràng buộc có 16. Đây là chẩn đoán phụ do tập được chọn theo đầu ra sau chạy, không thay test chính.


8. Theo chủ đề và hoạt động của λ

Lợi ích chưa xuất hiện đồng đều giữa các chủ đề



Hình 2. Accuracy và flip-rate theo chủ đề. Mẫu số flip lần lượt là 83, 34, 35 và 42 câu ban đầu đúng.

Đại số: flip 9 $\rightarrow$ 7, accuracy đều 51,25%. Hình học: flip 2 $\rightarrow$ 1, accuracy 23,75% $\rightarrow$ 24,38%. Lý thuyết số: flip giữ 4; tổ hợp/xác suất: giữ 5, nhưng accuracy ràng buộc thấp hơn GRPO một câu. Không thể nói cải thiện ở tất cả chủ đề.



Hình 3. λ sau bước train, cập nhật mỗi 32 bước; giá trị mới dùng ở bước tiếp theo. Điểm 128 không còn được dùng để train.

Đường λ không phải loss hoặc flip-rate. Ví dụ λ đại số sau bước 96 là 0,015, được dùng trong cửa sổ tiếp theo. Ngay cả khi λ cuối thay đổi, không có nghĩa thay đổi đó đã tác động vào adapter cuối.

Trong train có **9 lượt anchor sai/128 lượt kiểm tra = 7,03%**. Đây là tổng quan sát tại nhiều thời điểm, có thể lập bài; không phải tỷ lệ sai của toàn bộ 153 anchor tại checkpoint cuối và không thay flip-rate test 8,76%.

9. Độ tin cậy, kết luận và cách sử dụng

Tín hiệu nhỏ cần kiểm chứng; không thay đổi kết quả để làm đẹp báo cáo

9.1. Khoảng tin cậy

Bootstrap 2.000 lần giữ cặp dự đoán và lấy mẫu trong từng chủ đề. Chênh lệch ràng buộc trừ GRPO:

Chỉ số	Chênh lệch	Khoảng tin cậy 95%
Accuracy	+0,156 điểm %	[-0,781; +1,094] điểm %
Flip-rate	-1,546 điểm %	[-3,941; +0,532] điểm %

Cả hai khoảng chứa 0: chưa đủ bằng chứng về cải thiện ổn định. Bootstrap đo bất định do mẫu câu dưới model đã train; không thay thế nhiều training seed.

9.2. Hạn chế cần nêu khi báo cáo

Một seed, subset đáp án nguyên: không đại diện mọi dạng toán. **Test đã được xem trước** khi quyết định quay về feedback cửa sổ: không dùng test vào gradient, nhưng lựa chọn hướng thử nghiệm chịu thông tin từ test; đây là đánh giá thăm dò hậu nghiệm.

Reward phụ thuộc boxed answer, token limit và decoding; chưa kiểm tra toàn bộ bước suy luận. Mỗi cửa sổ chỉ 8 lượt kiểm tra/chủ đề, có thể nhiều. Anchor dựa trên lần đúng ban đầu; gold loss là surrogate và feedback trễ. Compute/update khác nhau; chưa tách tác động riêng của λ thích nghi khỏi tác động thêm gold loss.

9.3. Kết luận và hướng phát triển

Run này ghi nhận ít hơn 3 bài đúng → sai, accuracy hơn 1 bài và train thêm 34 phút. Có tín hiệu giữ đáp án đúng, nhưng chưa chứng minh vượt trội, bảo đảm không hồi quy, tính mới thuật toán hoặc tốt hơn các method không chạy trong run.

Nếu tiếp tục: dùng test chưa xem, nhiều seed và config chốt trước chạy; so thêm anchor loss trọng số cố định; khảo sát ngưỡng/cửa sổ trên validation; báo cáo accuracy, flip, gain và compute cùng nhau. Đây là kế hoạch, chưa là kết quả.

9.4. File, thao tác và nguồn số liệu

Xem kết quả: mở **visualize_results.ipynb**, Run All. Tạo lại bảng từ raw predictions local: compare.py → screen_report.py → notebook. Toàn pipeline: run_replication.py; nhánh hoàn tất sẽ được bỏ qua. Không tự train tiếp hoặc resume optimizer của nhánh bị ngắt.

GitHub giữ code, notebook, README, PDF và CSV results; không chứa cache model, adapter, frozen split hoặc raw predictions. Notebook có thể đọc results mà không cần GPU. Muốn train lại đúng tập cần artifact local; prepare_math_data.py không tự tạo split thay thế khi thiếu.

Nguồn: results/comparison.csv; results/paired_statistics.csv; results/retention_weights.csv; results/run_timing.json. Config: configs/math_retention.json. Công thức: src/plmco/math_trainer.py, math_model.py và retention.py. Dataset revision: 9bbe1fc38f097a38e3bdf5bbec8d6feee21318c9. Chính tài liệu không đổi code train hoặc kết quả.